

三维分形生成：基于 VQ-VAE 的由粗到细八叉树生成

余东格

2026 年 7 月

1 研究背景与问题

三维形状的生成如果在稠密体素上直接建模，会在大量空白区域浪费算力。八叉树把形状表示为由粗到细的层级结构：先在低分辨率判断大致占据区域，再逐层只在被占据的节点上细分，从而把计算集中在形状表面附近。OctGPT 沿这一思路，用一个自回归 Transformer 逐 token 生成八叉树，并配合一个冻结的 VQ-VAE 把叶子层的离散 token 解码为连续 SDF，质量很高，但代价是迭代式解码：每个样本需要约 576 次前向（各层 MaskGIT 迭代步数 [64, 128, 128, 256]），单样本推理约 43 秒。

本工作的核心研究问题是：一个单次前向（约 4 次 *forward*）的由粗到细生成器，能否逼近 OctGPT 这类迭代自回归模型的形状质量，从而以远低的推理成本换取可比的形状。我们复用 OctGPT 完全相同的冻结 VQ-VAE 作为叶子解码器，只把生成器换成由粗到细、少步前向的结构，这样质量差异可以干净地归因到生成器本身，而非解码器。

2 方法

生成器只负责预测八叉树结构与叶子层的 VQ token，解码交给冻结的 VQ-VAE。整体流程为：逐层预测 split $\rightarrow$ 展开到 `depth_stop=6` $\rightarrow$ 叶子层预测 VQ token $\rightarrow$ 冻结 VQ-VAE 解码为 SDF $\rightarrow$ marching cubes 得到网格。主要组成部分：

- **由粗到细的 split 预测**：从 `full_depth=3` 起，用 OctFormer 逐层

预测每个节点是否分裂，展开至 `depth_stop=6`，再由 zero split 扩到 `depth=8`。父节点通过局部 cross-attention 展开为 8 个子节点。

- **叶子层 VQ token 与冻结解码器：**叶子层预测离散 VQ token，由冻结 VQ-VAE 解码为连续 SDF，使叶子表示具备比纯占据更强的表面细节。
- **条件化：**原始无条件模型生成严重趋同（所有样本几乎相同）。为此引入类别嵌入与 VAE 隐变量 z （ z 由真值形状编码得到，生成时从 $\mathcal{N}(0, I)$ 采样），并在每一层注入条件。所有条件相关权重 zero-init，使加入条件后与 warm-start 起点严格等价。
- **sibling attention：**父节点展开为 8 个子节点时，原本的 cross-attention 上下文长度为 1，退化为逐节点 MLP，8 个兄弟节点之间不通信。加入 sibling self-attention 让同一父节点的 8 个八分体子节点互相 attend（真正的 $K = 8$ 注意力），得到更好的子节点特征，进而改善 split 预测。
- **split 监督：**节点是否分裂存在严重类别不平衡（split=1 很稀疏），采用 Focal Loss 监督。训练用 teacher forcing，沿真值八叉树逐层展开并监督每个节点的 split 与叶子 token。

3 单飞机过拟合验证

首先在单个飞机样本上过拟合，确认从 split 预测、VQ token 预测到 VQ-VAE 解码与 OBJ 导出的完整 pipeline 是可学习的。把消融中表现较好的结构性改动（sibling attention、粗层容量、全局 buffer）微调到单飞机上，split accuracy 收敛到 0.998（末层），VQ accuracy 约 0.847。结构（split）几乎完美，说明八叉树拓扑被准确学到、整条实现有效。

值得注意的是，早期导出的网格表面满布小孔。为定位这一现象的来源，我们做了一个 *oracle* 对照：把真值形状的叶子 token（经冻结 VQ-VAE 编码量化得到）直接送回同一个冻结 VQ-VAE 解码，得到“解码器上限”网格，再与我们生成器的输出并排比较（图 1）。二者几乎一致：*oracle* 与本方法生成的平均二面角分别为 14.0° 与 13.2° ， $> 60^\circ$ 的棱占比都是 2.6%。这说明小孔并非来自我们生成器的 split 或 token 误差。进一步排查发现真正的来源是 marching cubes 的等值面取值：默认 $\ell = 0.002$ 恰好落在冻结解

码器输出 SDF 的零点噪声带内，任何表面附近的微小符号抖动都会被抠成孔洞；把等值面提高到 $\ell = 0.01$ （对 depth-8、体素约 $2/256$ 的尺度而言仍是极薄的偏移）后，oracle 与生成结果的小孔同时消失，且该修复 无需任何重训练。图 1 即为 $\ell = 0.01$ 下的对照：上排 oracle、下排本方法，二者形状与表面质量几乎一致，机身、后掠翼、尾翼清晰可辨。换言之，在这个过拟合样本上，约 4 次前向的生成器已经达到了解码器自身的重建上限。



图 1: 单飞机过拟合的 oracle 对照（正视 / 3/4 视角 / 顶视，marching cubes 等值面 $\ell = 0.01$ ）。上排为真值 token 经同一冻结 VQ-VAE 解码得到的“解码器上限”，下排为本方法约 4 次前向的自由生成结果。二者形状与表面质量几乎一致，表明生成器已达到解码器自身在 depth-6 的重建上限。

4 多类别消融 (im-5)

在多类别 im-5 数据集（airplane / car / chair / rifle / table 五类）上，我们做了条件化、latent、模型扩容与迭代式 refinement 的消融。主要结果如表 1，指标为最后一层 split accuracy 与 VQ accuracy；参照是无条件 baseline。

如实来看：

实验	主要改动	split acc	末层 split acc	VQ acc
–	无条件 baseline (生成趋同)	~0.79	–	–
C2	类别条件每层注入	0.812	0.756	0.652
V1	C2 + latent z	0.836	0.780	0.647
Q2	768 维大模型	0.840	0.788	0.646
Q3	Q2 + split MaskGIT	0.836	0.776	0.644
Q4	Q2 + sibling attention	0.841–0.845	0.795–0.800	0.645–0.647
S1	V1 + leaf VQ MaskGIT	0.840	0.791	0.639

表 1: VQ-VAE 分形生成路线在 im-5 多类别数据上的主要消融结果。

- **条件化是关键**。无条件模型退化为预测边缘分布、样本趋同，split acc 停在约 0.79。加入类别条件与 latent z (C2、V1) 明显缓解趋同，不同类别可生成不同形状，split acc 提升到 0.84 附近。
- **扩容与 sibling 只有小幅增益**。768 维大模型 (Q2) 与 sibling attention (Q4) 带来小幅结构提升，Q4 是当前结构指标最好的版本 (末层 split acc 约 0.80)，但增益已很有限。
- **迭代式 refinement 是负结果**。Q3 的 split-MaskGIT 没有达到预期，迭代反而使结构变稀疏、碎片增多；它与特征级联式的单次前向架构不匹配。leaf VQ MaskGIT (S1) 对 nearest-CD 有一定趋势，但 S1 用的是 384 维配置，与 768 维的 Q4 不是严格同容量对照，不能直接比较。

5 空洞来源诊断与结构改进

多类别生成的网格长期存在“缺块/空洞、散点”的问题。表 1 中的 split accuracy 无法解释它：该指标被大量“不分裂”的负样本主导，掩盖了真正致命的错误类型。为此我们为每一层单独统计 split=1 类的查全率 (recall) 与查准率 (precision)，并构建了一个逐层按八叉树 key 对齐生成结构与真值结构的诊断工具，得到两个关键事实：

- **漏分裂的代价高度不对称**。depth d 上漏掉一个本应分裂的节点，会砍掉整棵子树 (至多 8^{6-d} 个叶子)，造成整块几何缺失；反之多分裂

只是表面变密。因此 recall 远比 accuracy 重要。

- **瓶颈在最粗层而非最细层。**以结构最好的 Q4 为例，teacher-forcing 下按生成阈值判决，depth-3（最粗层）的漏分裂率高达 21.4%（每个漏判平均丢约 57 个叶子），而 depth-5 仅 5.7%；自由生成时粗层错误逐层级联，depth-6 叶子缺失率达 29.3%，结构 IoU 仅 0.33。此前报告聚焦“末层 accuracy 约 0.80”是被指标定义误导的结论。

诊断同时给出了两个免训练的生成端修复：叶子 token 改用 argmax (temperature=0，消除 VQ 采样噪声在 0.65 左右的 token 准确率下渲染成的“雪花”)、marching cubes 等值面 $\ell = 0.01$ （第 3 节）。二者叠加使 chair/car 等类别从噪声云变为轮廓清晰的实体。

针对粗层瓶颈，我们在 Q4 基础上引入两个训练侧改动（记为 R2, warm-start 自 Q4）：**(1) 粗层加权 split loss**，按子树代价给各层 loss 乘以 [4, 2, 1] 权重；**(2) 空间池化 latent**：原 z 是叶子 VQ code 的全局平均，不含空间布局信息，诊断显示模型完全忽略它（用真值后验 z 与先验采样 z 生成的结构完全相同）；改为按 $8^3 = 512$ 个 depth-3 空间格分别池化后再编码，使 z 携带粗层布局。在 im-5 上训练 20 epoch 后：depth-3 recall 从 0.786 升至 0.950，自由生成叶子缺失率从 29.3% 降至约 5%，结构 IoU $0.33 \rightarrow 0.44$ ，VQ accuracy $0.645 \rightarrow 0.681$ ，且后验/先验 z 的生成结构不再相同（latent 开始生效）。但代价是细层查准率降至约 0.75：模型整体向“宁多勿漏”偏移，多余的分裂把机翼间隙等凹陷填成实心，airplane/car 的轮廓反而变差，而 chair/rifle/table 改善。这揭示了单次前向框架下 recall 与轮廓质量之间的张力，我们在第 6 节进一步讨论其根源。

6 速度对比

主要卖点是推理成本。生成器前向次数约 4 次（由粗到细逐层各一次）对比 OctGPT 的约 576 次迭代解码，且两者共用同一冻结 VQ-VAE。实测见表 2。

生成器部分约 300 倍加速；端到端约 21 倍，其瓶颈是两种方法共享的 marching cubes（res=256 约 3.5 秒，res=512 约 20 秒），并非生成器本身。

方法	前向次数/样本	生成器耗时	端到端 (含 marching cubes)
OctGPT (官方权重, 实测)	~576	~77 s	~81 s
本方法 (单次前向)	~4	~0.23 s	~3.8 s

表 2: 推理速度对比 (同一台 A100、同一冻结 VQ-VAE, res=256)。OctGPT 为官方发布的 airplane 权重实测 (每样本约 81 s); 本方法生成器约 4 次前向、0.23 s。生成器部分约 300 倍加速, 端到端约 21 倍; 端到端瓶颈是两者共享的 marching cubes (res=256 约 3.5 s)。



图 2: OctGPT 官方 airplane 权重配同一冻结 VQ-VAE 的生成样本 (实测约 81 s /样本)。它验证了两件事: 解码器本身有能力输出光滑表面 (我们多类别结果表面粗糙主要来自 token 预测质量而非解码器), 以及迭代式生成在轮廓上仍显著优于单次前向, 这正是表 2 中速度优势所换取的代价。

7 结论与不足

本工作搭通了“由粗到细 split 预测 + 叶子 VQ token + 冻结 VQ-VAE 解码 + marching cubes”的完整训练与生成流程，在单飞机上验证了 pipeline 可完整拟合，并在 im-5 多类别上通过条件化修复了生成趋同问题，同时在推理速度上相对 OctGPT 有明显优势。主要不足：

- **根本限制：独立边缘判决的模式平均。** 单次前向对每个节点按 独立的边缘概率判决是否分裂。当类内存在多种布局模式（不同机翼位置、不同桌腿结构）时，各节点的边缘概率被拉向多模式的平均，生成结果趋向“类别平均形状”（飞机的实心三角翼团块即由此而来）。空间池化 latent 缓解但不足以完全消除；OctGPT 的 576 步迭代每步都以已确定的部分结构为条件、逐步承诺到单一模式，这正是质量差距的本质来源。
- **recall 与轮廓质量的张力。** 第 5 节的 R2 实验显示：把粗层漏分裂率从 21% 压到 5% 的同时，细层查准率跌至约 0.75，过度分裂把凹陷填成实心。在“独立判决”框架内，向 recall 倾斜与保持轮廓锐利难以两全。
- **表面细节受限于 token 质量。** OctGPT 官方权重配同一解码器可输出光滑表面（图 2），说明解码器不是上限；我们多类别 VQ accuracy 仅约 0.68，token 误差在表面上渲染为颗粒感，argmax 采样与 $\ell = 0.01$ 只能部分掩盖。

基于以上分析，最有希望的后续方向是仅在最粗层引入少步迭代：depth-3 只有至多 512 个节点，做 4-8 步 MaskGIT 式 refinement 仅增加约 8 次前向（总前向仍 ~ 12 次，保持约 50 倍生成器加速），却把“模式承诺”引入了错误代价最高的一层。它与已失败的全层 split-MaskGIT（Q3）的区别在于只作用于粗层且训练/生成策略匹配。此外还应补齐 MMD-CD / COV / 1-NNA 量化指标，在“速度-质量”曲线上系统对比本方法与 OctGPT。